

逻辑回归（对数几率回归）

一、逻辑回归

$$\text{逻辑回归模型: } \log\left(\frac{p}{1-p}\right) = w_0 + \sum_{j=1}^d w_j x_j + u = \tilde{W}^T \tilde{X} \quad (1)$$

$$\text{通过(1)式反解可以得到: } p = \frac{1}{1 + e^{-\tilde{W}^T \tilde{X}}} \quad (2)$$

而 (2) 式是一种 sigmoid 函数，它将 x 值转化为一个接近 0 或 1 的 y 值：



$$\varphi(x) = \frac{1}{1 + e^{-x}} \quad \text{其图像大致为}$$

若将 p 视为样本 x 作为正例的可能性，则 $1-p$ 是其反例的可能性，两者的比值 $\frac{p}{1-p}$ 称为“几率”，反映了 p 作为正例的相对可能性。所以(1)式其实是在用线性回归模型的预测结果去逼近真实标记的对数几率。

由于 sigmoid 函数的取值在 $[0,1]$ 之间，所以可以将其视为类 1 的后验概率估计 $p(y=1|x)$ ，所以我们把 sigmoid 函数计算得到的值大于等于 0.5 的归为类别 1，小于 0.5 的归为类别 0。

二、 最大似然估计

逻辑回归的第一个假设是：假设数据服从伯努利分布。第二个假设为假设模型的输出值是样本为正例的概率。所以整个模型可以描述为：

$$h_{\theta}(x; \theta) = p = \frac{1}{e^{-\theta^T x} + 1} \quad \theta = (w; b)$$

若模仿线性回归的做法（利用误差平方和作为代价函数），则会发现得到的结果是一个非凸函数，不利于求解，所以选取最大似然作为 cost function.

因为逻辑回归是一种训练学习，所以 $h_{\theta}(x; \theta)$ 可以视为类 1 的后验概率，则：

$$h_{\theta}(x; \theta) = p(p = 1|x; \theta) = \varphi(w^T + b) = \varphi(z) = \frac{1}{1 + e^{-\theta^T x}}$$

$$p(p = 0|x; w) = 1 - \varphi(z)$$

合并之后得到：

$$p(p|x; \theta) = h_{\theta}(x; \theta)^p (1 - h_{\theta}(x; \theta))^{1-p}$$

则极大似然估计函数为：

$$\prod_{i=1}^n (p_i)^{y_i} (1 - p_i)^{1-y_i}$$

取对数之后：

$$L(\tilde{\mathbf{W}}) = \sum_{i=1}^n (y_i \log p_i + (1 - y_i) \log(1 - p_i))$$

$$= \sum_{i=1}^n \left(y_i \log \frac{p_i}{1 - p_i} + \log(1 - p_i) \right)$$

$$= \sum_{i=1}^n \left(y_i \tilde{\mathbf{W}}^T \tilde{\mathbf{X}}_i - \log(1 + e^{\tilde{\mathbf{W}}^T \tilde{\mathbf{X}}_i}) \right)$$

$$\frac{\partial L(\tilde{\mathbf{W}})}{\partial \tilde{\mathbf{W}}} = \sum_{i=1}^n \left[\left(y_i - \frac{e^{\tilde{\mathbf{W}}^T \tilde{\mathbf{X}}_i}}{1 + e^{\tilde{\mathbf{W}}^T \tilde{\mathbf{X}}_i}} \right) \tilde{\mathbf{X}}_i \right]$$

需要求得使 $L(\tilde{W})$ 最大的 \tilde{W} ，在其前面加一个负号就变为最小化负对数似然函数：

$$C(\tilde{W}) = -L(\tilde{W}) = -\sum_{i=1}^n (y_i \log p_i + (1 - y_i) \log(1 - p_i))$$

所以，如果样本的类别为 1/0，估计值越接近 1/0 付出的代价越小，反之越大。

三、 梯度回归

因为梯度的负方向就是代价函数下降最快的方向，所以可以通过迭代求梯度更新权重来求解。

重复此公式：

$$\begin{aligned}\tilde{W}_{new}^{(j)} &= \tilde{W}^{(j)} - \eta \frac{\partial C(\tilde{W})}{\partial \tilde{W}^{(j)}} \\ &= \tilde{W}^{(j)} - \eta \sum_{i=1}^n \left[\left(\frac{e^{\tilde{W}^T \tilde{X}_i}}{1 + e^{\tilde{W}^T \tilde{X}_i}} - y_i \right) \tilde{X}_i^{(j)} \right]\end{aligned}$$

直到 \tilde{W} 收敛